Jezički invarijantna provera semantičke ekvivalentnosti strukturno sličnih segmenata imperativnog koda

Ivan Ristović

Teme

- Motivacija i uvod
- AST
- Dobijanje AST - ANTLR
- Opšti AST
- Poređenje opštih AST
- LICC — Language Invariant Code Comparer

Motivacija i uvod

```
1  void array_sum(int[] arr, int n) {
2      int sum = 0, i = 0;
3      while (i < n) {
4          int v = arr[i]
5          sum += v;
6          i++;
7      }
8      return sum;
9  }
```

```
1  function array_sum(arr, n)
2      local sum = 0
3      for i,v in ipairs(arr) do
4          sum = sum + v
5      end
6      return sum
7  end
```

Uvod i motivacija

- Pristup?
  - "Niski"pristup
  - "Visoki"pristup
- Razlika je u reprezentaciji na koju se dovode segmenti koda pre procesa poređenja

Uvod i motivacija

- Niski pristup

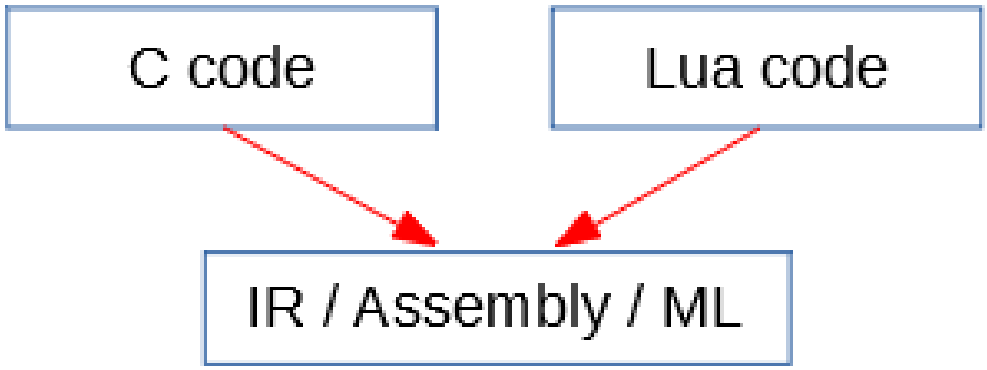

- Prednosti: jedinstvena reprezentacija (?)
- Mane: vezanost sa specifičnom arhitekturom procesora, potrebno prevoditi kod, JVM/CLR, razliciti programski jezici?

Uvod i motivacija

- Visoki pristup (varijanta 1)

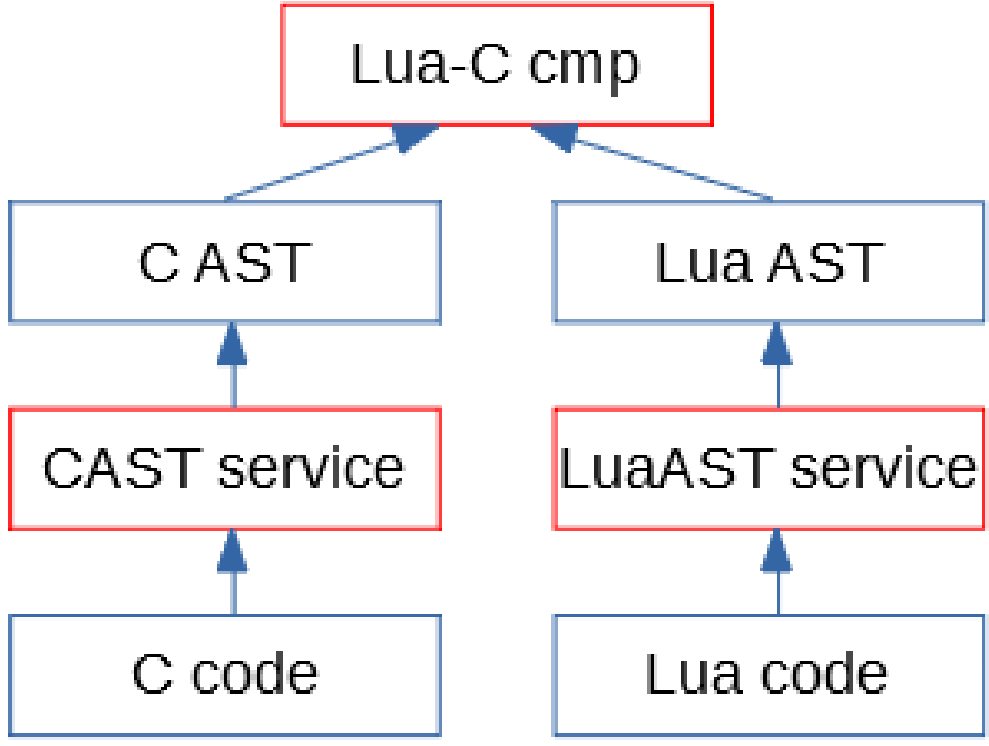

- Prednosti: jedinstvena reprezentacija (?), nije potrebno prevoditi kod, kompatibilno sa bilo kojim programskim jezikom, moguće koristiti algoritme za poređenje stabala
- Mane: zavisnost od eksternih servisa, skaliranje

Uvod i motivacija

- Visoki pristup (varijanta 2)

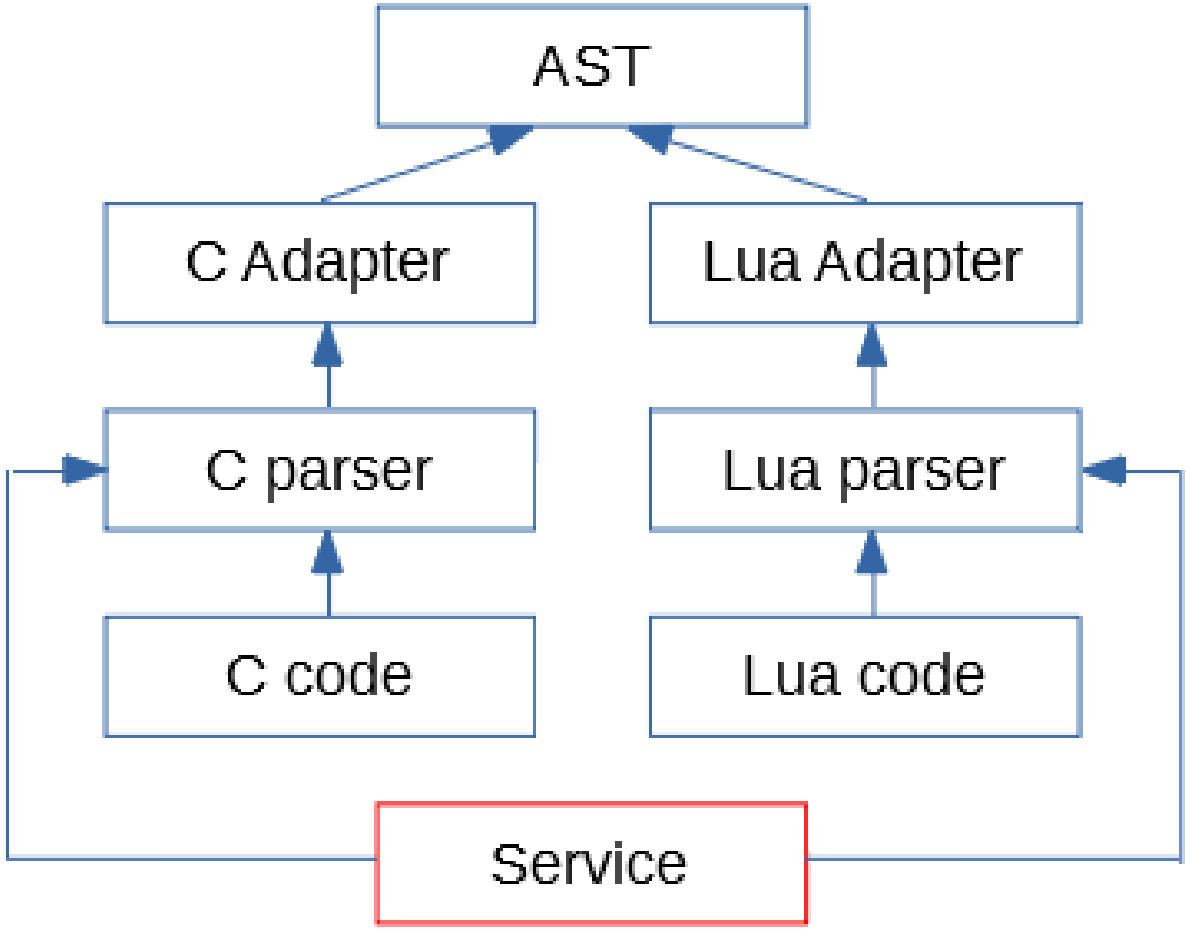

- Prednosti: jedinstvena reprezentacija (!), nema prevođenja, proizvoljan programski jezik, moguće koristiti algoritme za poređenje stabala, skalabilno, samo jedan servis

Uvod i motivacija

- Pošto nema prevođenja, može se analizirati kod samo na osnovu gramatike njegovog jezika
- AST se dobija od stabla parsiranja izvornog koda korišcenjem adaptera
- Adapteri se moraju razlikovati zbog razlika u AST

Uvod i motivacija

- Kako proširiti?

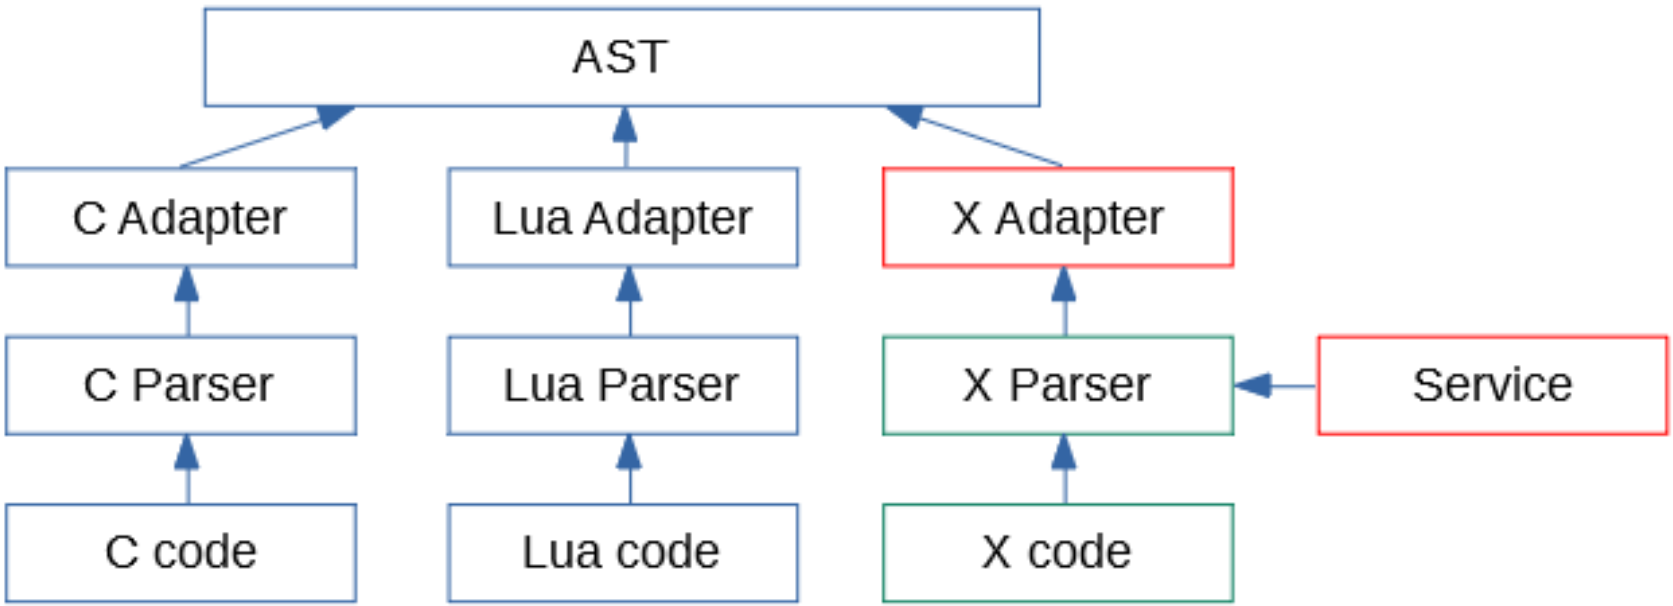

AST

- AST - Abstract Syntax Tree

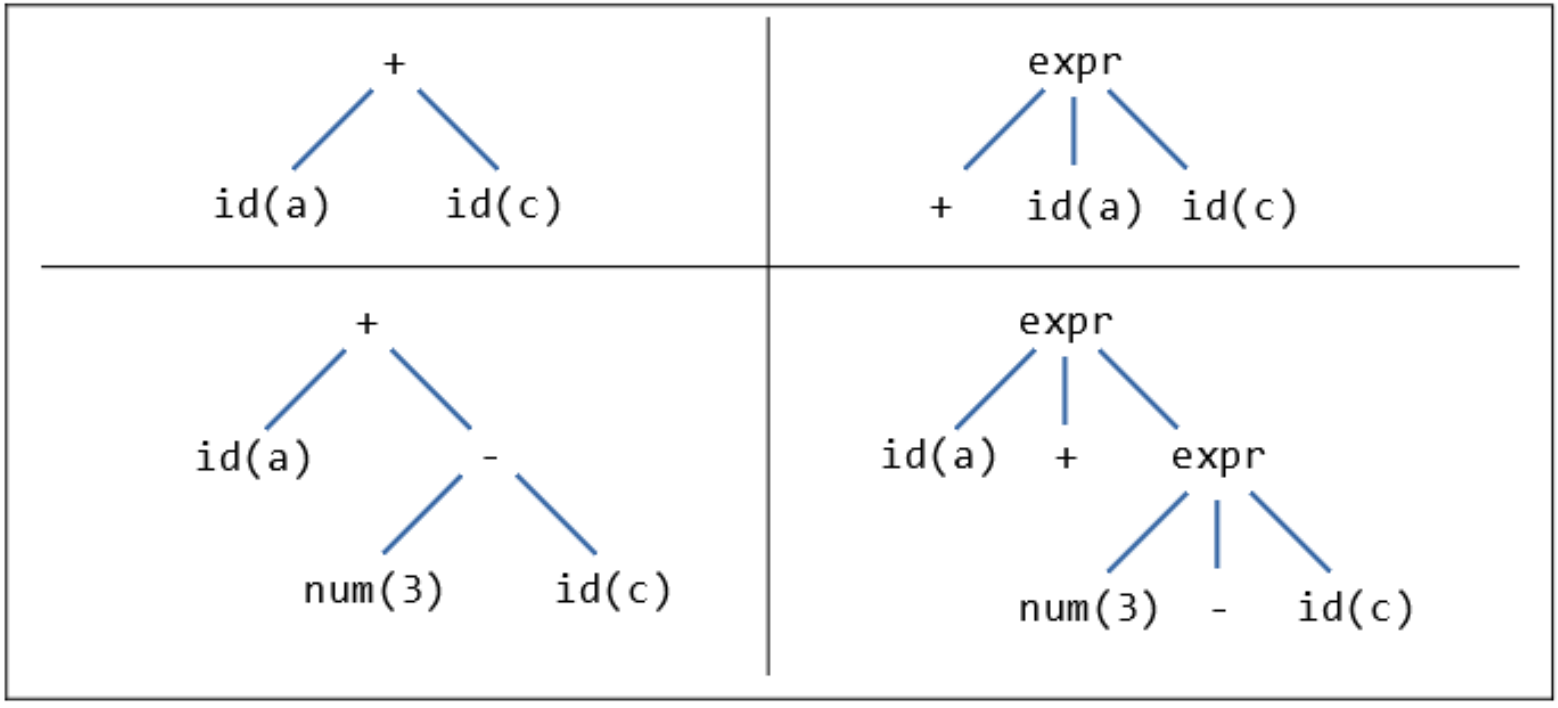

AST

- Go AST

```
package main

import "fmt"

func fib() func() int {
    a, b := 0, 1
    return func() int {
        a, b = b, a+b
        return a
    }
}
```

```
- File  {
    Comments: [ ]
  - Decls:  [
    + GenDecl {Loc, Lparen, Rparen, Specs, Tok}
    - FuncDecl  {
      - Body: BlockStmt  {
          Lbrace: 55
        - List:  [
          + AssignStmt {Lhs, Loc, Rhs, Tok}
          - ReturnStmt  {
            + Loc: {End, Start}
            - Results:  [
```

AST

- Lua AST

```
function Fibonacci.naive(n)
  local function inner(m)
    if m < 2 then
      return m
    end
    return inner(m-1) + inner(m-2)
  end
  return inner(n)
end
```

```
- Chunk  {
    type: "Chunk"
  - body:  [
    - FunctionDeclaration  {
        type: "FunctionDeclaration"
      + identifier: MemberExpression {type,
        isLocal: false
      + parameters: [1 element]
      - body:  [
        - FunctionDeclaration  {
            type: "FunctionDeclaration"
          + identifier: Identifier {type,
```

Dobijanje AST - ANTLR

- Neophodan je parser!
- AST nastaje apstrahovanjem stabla parsiranja
- Dosta alata: Yacc, BYACC, GNU Bison, ANTLR
- Svi ovi alati mogu generisati parsere za proizvoljne gramatike

Dobijanje AST - ANTLR

- *ANother Tool for Language Recognition*
- ANTLR v4 izabran zbog:
  - Mogućnosti generisanja parsera u raznim jezicima (uključujući C#)
  - Trivijalno definisati gramatike (dosta poznatih jezika već podržano)
  - Mogu se generisati i klase koje pružaju interfejs za obilazak stabla parsiranja

Dobijanje AST - ANTLR

- Prvi korak: definicija gramatike

```
1  grammar Lua;
2  chunk : block EOF ;
3  block : stat* retstat? ;
4  stat
5      : ';'
6      | varlist '=' explist
7      | functioncall
8      | label
9      | 'break'
10     | 'do' block 'end'
11     | 'while' exp 'do' block 'end'
12     | 'if' exp 'then' block ('elseif' exp 'then'
           block)* ('else' block)? 'end'
13     | 'for' NAME '=' exp ',' exp (',' exp)? 'do'
           block 'end'
14     | 'function' funcname funcbody
15     ...
```

Dobijanje AST - ANTLR

- Prvi korak: definicija gramatike

```
1  NAME
2       : [a-zA-Z_][a-zA-Z_0-9]*
3       ;
4
5  NORMALSTRING
6       : '"' ( EscapeSequence | ~('\\'|'"') )* '"'
7       ;
8
9  WS
10      : [ \t\u000C\r\n]+ -> skip
11      ;
```

Dobijanje AST - ANTLR

- Drugi korak: generisanje parsera

```
1  $ antlr4 Lua.g4 -Dlanguage=CSharp --visitor
```

- Generisane `LuaLexer` i `LuaParser` klase
- Generisani interfejsi `LuaListener` i `LuaVisitor`

Dobijanje AST - ANTLR

- Treći korak: obići stablo parsiranja i kreirati AST

```
1  public interface ILuaVisitor<T> :
       IParseTreeVisitor<T>
2  {
3      T VisitChunk([NotNull]
           LuaParser.ChunkContext context);
4      T VisitBlock([NotNull]
           LuaParser.BlockContext context);
5      T VisitStat([NotNull] LuaParser.StatContext
           context);
6
7      ...
8  }
```

Opšti AST

- Želimo opšti AST, koji će podržavati koncepte raznih imperativnih jezika
- Koncepti: literali, izrazi, naredbe, ...
- Kreirati dovoljno (ali ne previše) apstraktne tipove čvora za ove koncepte
- Specifičnosti svesti na "već viđeno"
- Ako svođenje nema smisla, uvesti novi tip AST čvora
- Izgubiti što manje informacija!!!

Opšti AST

- Bazna hijerarhija

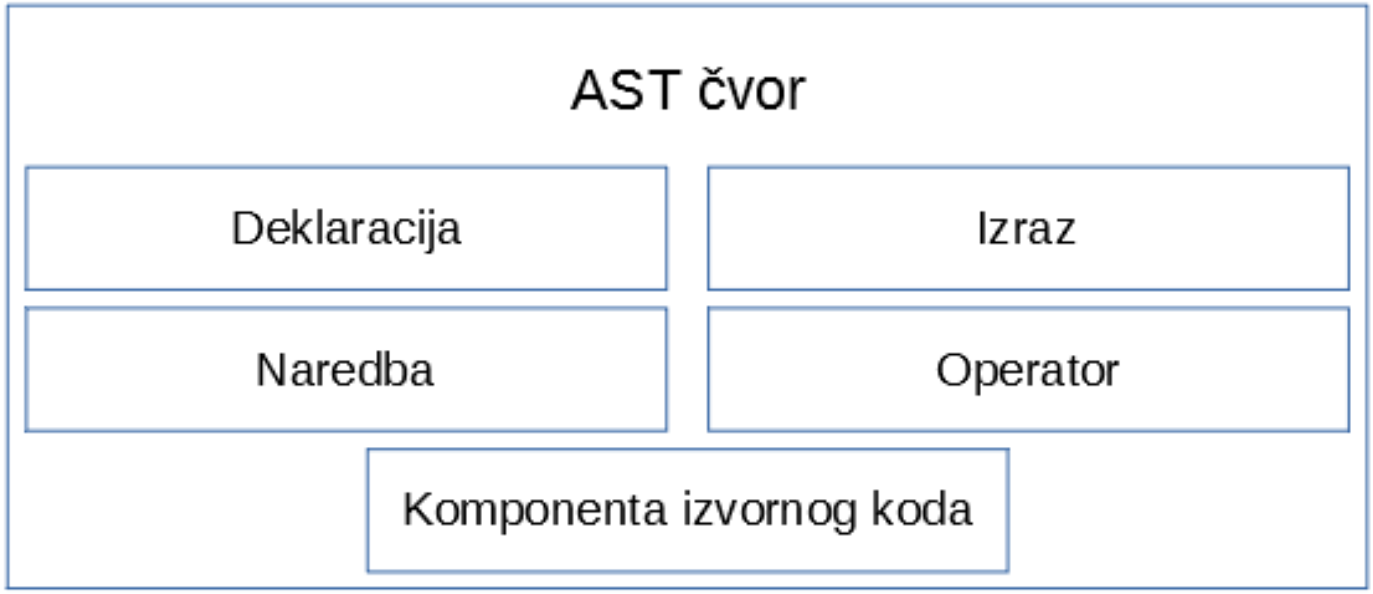

Opšti AST

- Operatori

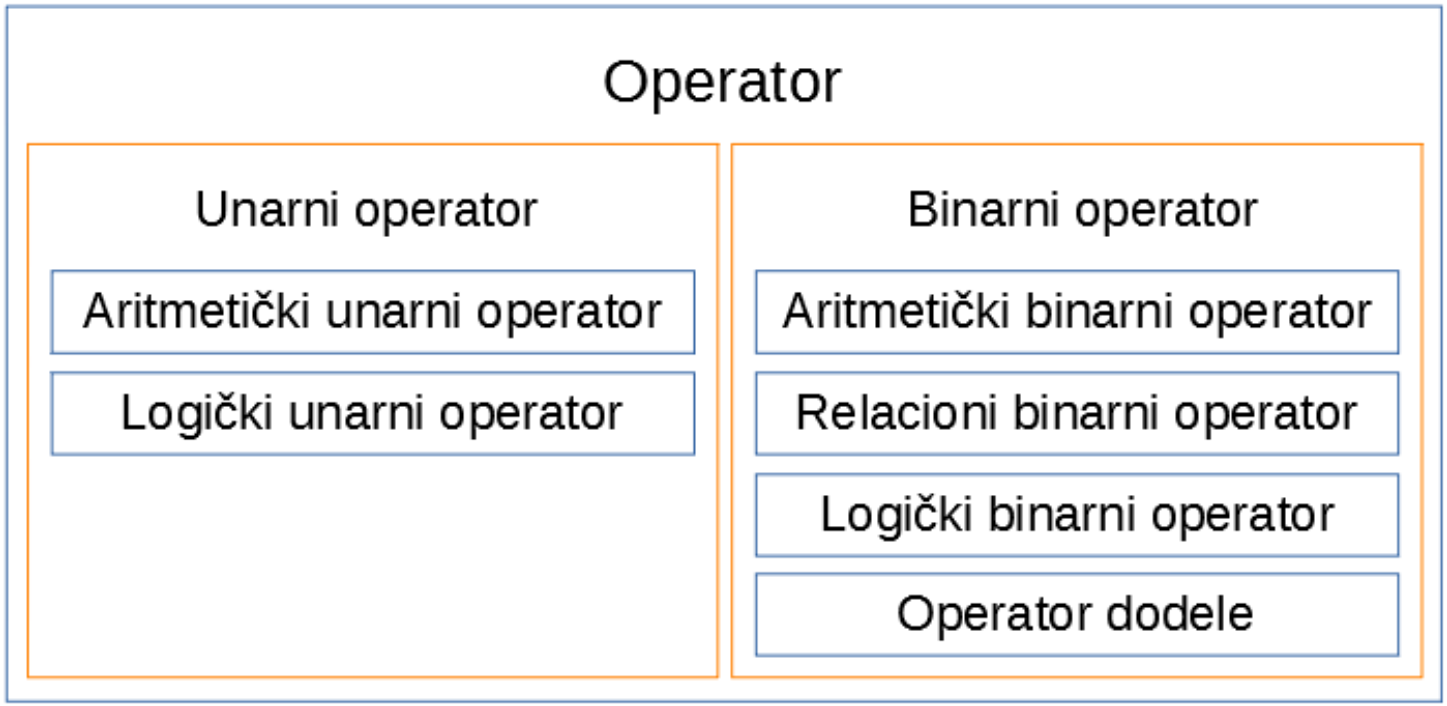

Opšti AST

- Izrazi

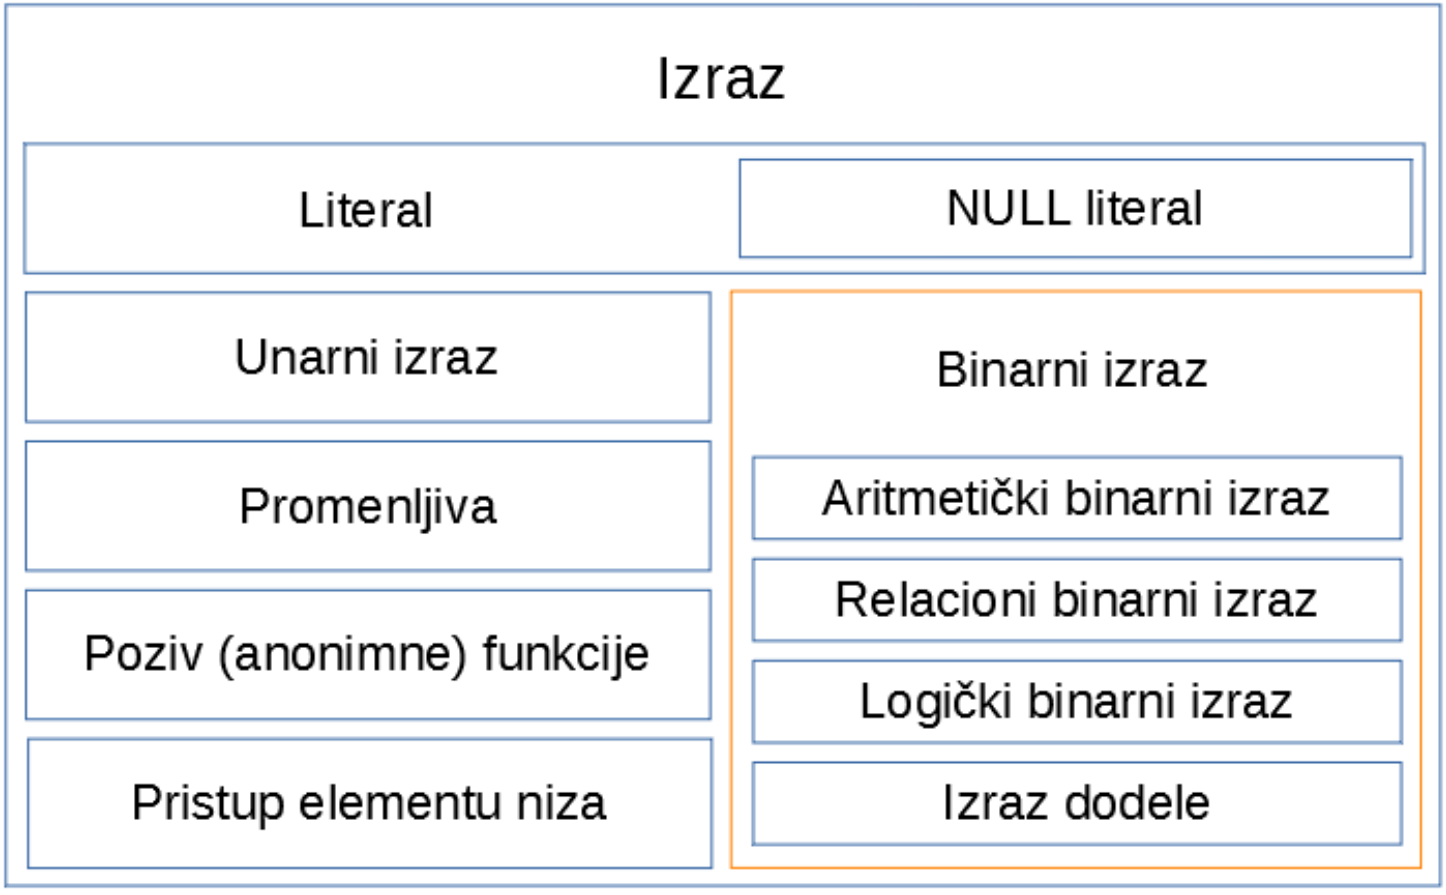

Opšti AST

- Deklaracije

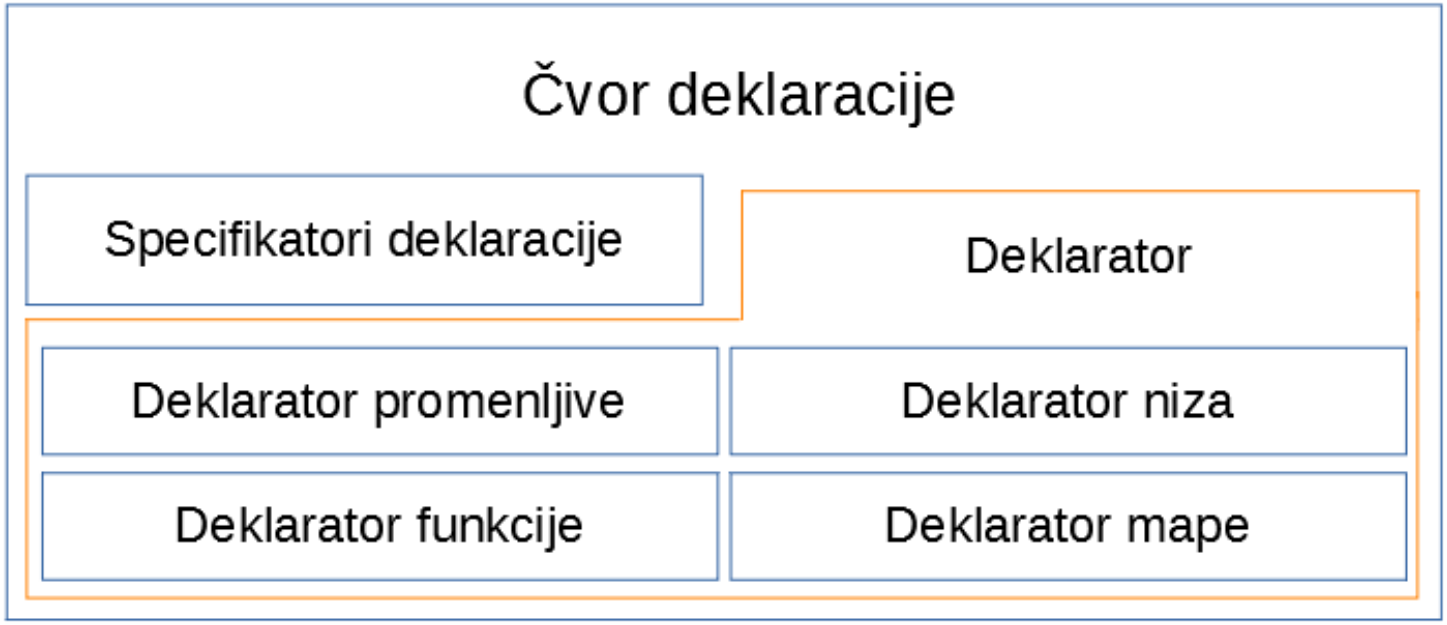

Opšti AST

- Naredbe

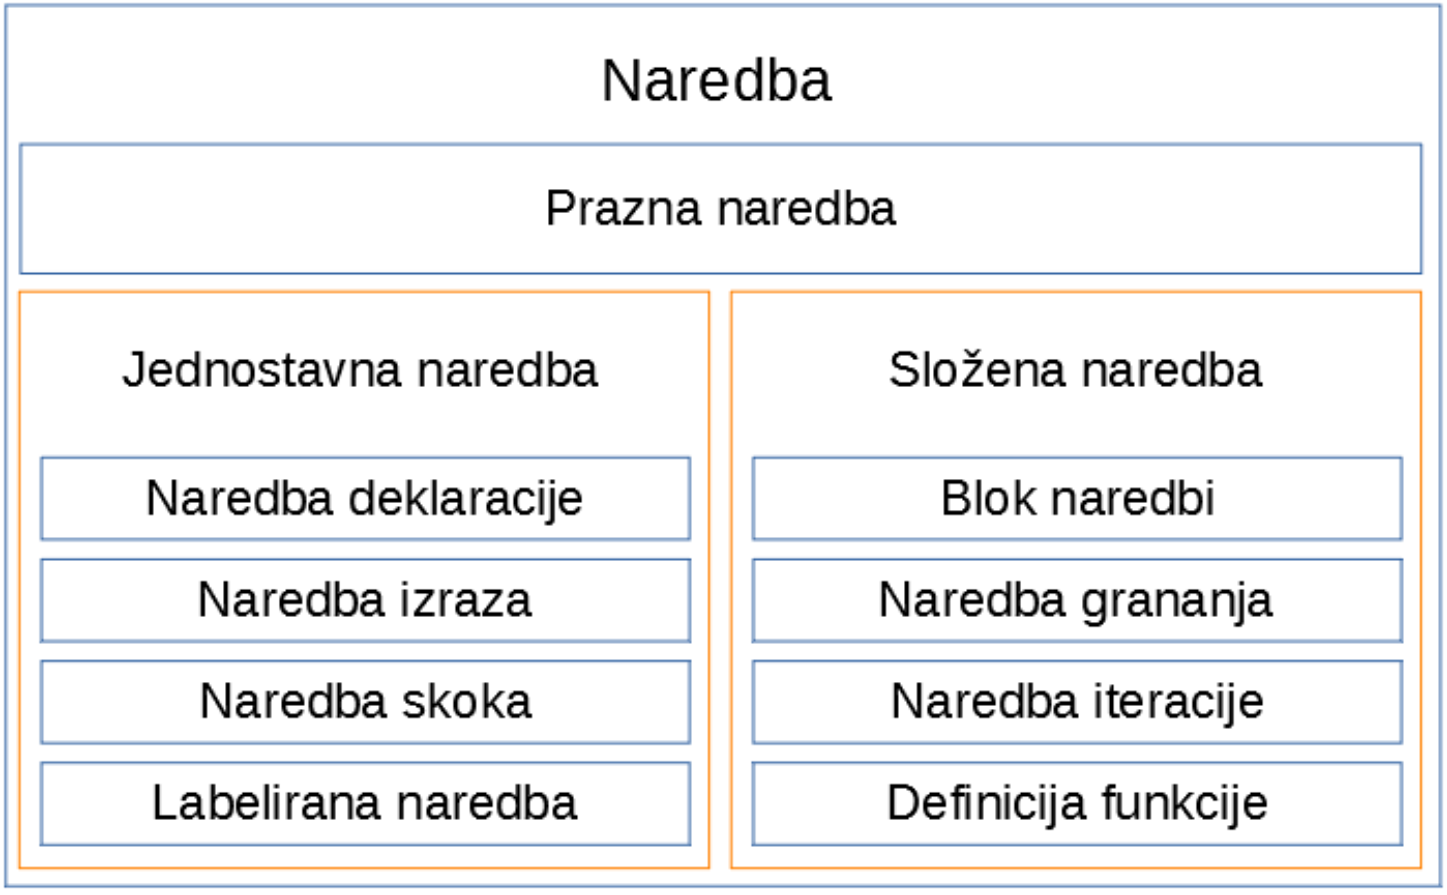

Opšti AST

- Primer - *swap*

```
1  int tmp = x;
2  x = y;
3  y = tmp;
```

```
1  x, y = y, x
```

- Paziti na nove konstrukte
- U slučaju skript jezika, deklarisati promenljive pre korišćenja

Gde smo sada?

- x Motivacija i uvod
- x AST
- x Dobijanje AST - ANTLR
- x Opšti AST
- Poređenje opštih AST
- LICC — Language Invariant Code Comparer

Pitanja

???